PSIntelligence 101-1

로켓 에비오닉스의 기초: 확률적 상태 추정과 선형 칼만 필터

---

0. 시작하며: 왜 Linear Kalman Filter에서 시작하는가?

PSLV의 에비오닉스는 NURA 대회와 연말발사 비행 과정에서 다양한 센서를 통해 다양한 데이터를 수집한다. 이를 바탕으로 PSI에서는 현재 고도 추정, 낙하산 사출 조건 결정 및 수행, GPS 좌표 기반 비행 지도 제작, 추후 진행될 에어 브레이크와 카나드 제어, 다단 사출 등과 같은 특수 미션을 설계한다. 이때, 이 모든 과정의 기초가 되는 것이 바로 **'깨끗하고 정확한 데이터'**이다.

실제 비행 중인 로켓의 센서는 엔진의 진동, 기체의 흔들림, 그리고 하드웨어 자체의 한계로 인해 끊임없이 노이즈가 섞인 데이터를 내뱉는다.

이 지저분한 데이터를 그대로 에비오닉스 내부에서 활용하게 된다면, 정상적인 미션 수행이 불가능할 뿐더러, 매년 수천만원의 개발비를 투입하고도 고등학생 수준의 물로켓에서 벗어나지 못하는 셈이다.

따라서 우리는 PSLV 기반 미션을 수행하기에 앞서, 그리고 이어지는 PSIntelligence 저서에서 보일 것과 같이 미래를 예측하기에 앞서, **'현재 로켓이 어디에 있고 어떤 상태인지'**를 확률적으로 추론하는 법을 배워야 한다. 이것이 바로 상태 추정(State Estimation)이며, 그 중심에 **칼만 필터(Kalman Filter)**가 있다.

본 문서에서는 칼만 필터를 이해하기 위한 통계적 기초부터 선형 시스템에서의 추정 이론을 다룬다.

---

1. 통계적 기초 (Statistical Background)

1.1 기댓값(Expectation)과 평균(Mean)

확률 변수 X가 가질 수 있는 모든 값에 대해, 각 값과 그 값이 나올 확률을 곱하여 합한 값이다. 칼만 필터에서는 상태 변수나 잡음의 평균적인 거동을 나타내며, 보통 잡음의 평균을 0으로 가정한다.

- 이산 확률 변수: $E[X] = \mu_X = \sum x_i P(X = x_i)$
- 연속 확률 변수: $E[X] = \mu_X = \int_{-\infty}^{\infty} x f(x) dx$
- 벡터의 기댓값: 확률 벡터 $X = [X_1, X_2, \ldots, X_n]^T$의 기댓값은 각 성분의 기댓값으로 이루어진 벡터이다.

1.2 분산(Variance)과 불확실성

확률 변수가 기댓값으로부터 얼마나 퍼져 있는지를 나타내는 척도이다. 분산이 클수록 데이터가 넓게 퍼져 있으며, 이는 곧 **불확실성(Uncertainty)**이 높음을 의미한다.

$$Var(X) = \sigma_X^2 = E[(X - \mu_X)^2] = E[X^2] - (E[X])^2$$

- 분산이 작을수록 데이터가 평균 주변에 밀집되어 있음 = 불확실성이 낮음

- 분산이 클수록 데이터가 넓게 퍼져 있음 = 불확실성이 높음

1.3 공분산(Covariance)과 상관관계

두 확률 변수 X와 Y가 함께 변하는 정도를 나타낸다.

- $Cov(X, Y) = \sigma_{XY} = E[(X - \mu_X)(Y - \mu_Y)]$
- $\sigma_{XY} > 0$: X가 증가할 때 Y도 증가하는 경향.
- $\sigma_{XY} \approx 0$: 두 변수 간의 선형적 관계가 거의 없음(독립).

1.4 공분산 행렬 (Covariance Matrix)

다변수 확률 벡터 X의 공분산 행렬 P는 각 성분 간의 공분산을 요소로 하며, 시스템의 전체적인 불확실성을 표현하는 핵심 도구이다.

$$P = E[(X - \mu_X)(X - \mu_X)^T]$$

혹은 풀어서 썼을 때,

$$P = \begin{bmatrix} \mathrm{Var}(X_1) & \mathrm{Cov}(X_1, X_2) & \cdots & \mathrm{Cov}(X_1, X_n) \\ \mathrm{Cov}(X_2, X_1) & \mathrm{Var}(X_2) & \cdots & \mathrm{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{Cov}(X_n, X_1) & \mathrm{Cov}(X_n, X_2) & \cdots & \mathrm{Var}(X_n) \end{bmatrix}$$

공분산 행렬은 대칭 행렬(Symmetric)이며 양의 준정부호(Positive Semi-Definite, PSD) 성질을 갖는다.

즉, 임의의 벡터 z에 대해 $z^T P z \geq 0$을 만족해야 하며, 이는 분산이 항상 0보다 크거나 같아야 한다는 물리적 타당성을 보장한다.

확률 벡터 X (평균 μ_X, 공분산 P_X)와 상수 행렬 A에 대해, 새로운 확률 벡터 $Y = AX$를 정의하자. Y의 평균은 $E[Y] = A\mu_X$이 된다.

Y의 공분산 행렬 $P_Y = \mathrm{Cov}(Y)$는

$$\begin{aligned} P_Y &= E[(Y - E[Y])(Y - E[Y])^T] \\ &= E[(AX - A\mu_X)(AX - A\mu_X)^T] \\ &= E[A(X - \mu_X)(A(X - \mu_X))^T] \\ &= E[A(X - \mu_X)(X - \mu_X)^T A^T] \quad (\text{since } (MN)^T = N^T M^T) \\ &= AE[(X - \mu_X)(X - \mu_X)^T]A^T \quad (A, A^T \text{is constant}) \\ P_Y &= AP_X A^T \end{aligned}$$

1.4.1 공분산 행렬의 양의 준정부호성 (PSD) 증명

1. 임의의 0이 아닌 상수 벡터 $z \in \mathbb{R}^n$를 가정
2. 새로운 스칼라 확률 변수 Y를 아래와 같이 정의하면

$$Y = z^T X = z_1 X_1 + z_2 X_2 + \cdots + z_n X_n$$

3. 분산의 성질 $\mathrm{Var}(a^T X) = a^T \mathrm{Var}(X) a$ 에 의해

$$\mathrm{Var}(Y) = \mathrm{Var}(z^T X) = z^T E[(X - \mu_X)(X - \mu_X)^T] z = z^T P z \geq 0$$

4. 칼만 필터에서 공분산 행렬은 오차의 불확실성, 프로세스의 불확실성, 측정의 불확실성을 나타내는 필수 개념으로 작용한다.

---

2. 가우시안 분포 (Gaussian Distribution)

칼만 필터는 시스템의 잡음이 가우시안 분포(정규 분포)를 따른다고 가정한다. 가우시안 분포는 평균(μ)과 분산(σ^2)만으로 정의되며, 정규분포로도 불린다.

- 단일 변수 $X \sim \mathcal{N}(\mu, \sigma^2)$의 확률 밀도 함수(PDF):

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- **Multivariate Gaussian Distribution:** n차원 확률 벡터 $X \sim \mathcal{N}(\mu, P)$의 PDF:

$$f(x|\mu, P) = \frac{1}{(2\pi)^{n/2}|P|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^T P^{-1}(x-\mu)\right)$$

- **중요 성질: 선형 변환의 보존** 만약 $X \sim \mathcal{N}(\mu, P)$이고 $Y = AX + b$라면, 변환된 Y 역시 가우시안 분포를 따르며 그 확률 분포는 다음과 같다.

$$Y \sim \mathcal{N}(A\mu + b, APA^T)$$

  이 성질 덕분에 칼만 필터는 선형 변환 하에, 가우시안 분포를 수학적으로 유지하며 최적해를 도출할 수 있다.

---

3. 시스템 모델링 (System Modeling)

로켓의 비행을 수학적으로 표현하기 위해 **상태 공간 모델(State-Space Model)**을 도입한다.

3.1 상태 방정식 (State Equation)

시간 $k-1$에서 k로의 시스템 변화를 기술한다.

$$x_k = F_k x_{k-1} + B_k u_k + w_{k-1}$$

- x_k: 상태 벡터 (예: [위치, 속도, 가속도] ^{T})

ex) PSI의 LFK 에서는 [z, v_z] ^{T} 를 사용한다.

- F_k: 상태 전이 행렬 (시스템 동역학)

ex) 위 예시 상태 벡터에 대해, 전이 행렬은 아래와 같다.

$$\begin{bmatrix} 1 & dt \\ 0 & 1 \end{bmatrix}$$

- u_k: 제어 입력 (예: 엔진 추력)

ex) PSI의 LFK에서는 z 방향 가속도를 입력으로 사용한다. 즉 제어 입력은 a_z 이다.

- B_k : 입력 행렬 (제어 입력 u_k가 상태에 미치는 영향)

ex) 위 예시 제어 입력 벡터에 대해, 입력 행렬은(이 경우에는 벡터) 아래와 같다.

$$\begin{bmatrix} 0.5(dt)^2 \\ dt \end{bmatrix}$$

- w_k: 프로세스 잡음 (모델의 불완전성, 외란) $\sim \mathcal{N}(0, Q_k)$ → 가우시안 형태로 가정한다.

괜히 행렬식으로 표현하니 어려워 보일 수 있지만, PSI에 적용한 예시로 표현하자면,

$$\begin{aligned} \begin{bmatrix} z_k \\ v_{z,k} \end{bmatrix} &= \begin{bmatrix} 1 & dt \\ 0 & 1 \end{bmatrix} \begin{bmatrix} z_{k-1} \\ v_{z,k-1} \end{bmatrix} + \begin{bmatrix} 0.5(dt)^2 \\ dt \end{bmatrix} a_{z,k-1} + \begin{bmatrix} \epsilon_z \\ \epsilon_{v_z} \end{bmatrix} \\ &= \begin{bmatrix} z_{k-1} + v_{z,k-1}dt + 0.5a_{z,k-1}(dt)^2 + \epsilon_z \\ v_{z,k-1} + a_{z,k-1}dt + \epsilon_{v_z} \end{bmatrix} \end{aligned}$$

평범한 dt 간격의 등가속도 공식과 동일하다.

3.2 측정 방정식 (Measurement Equation)

k 단계에서 센서가 상태 x_k를 어떻게 관측하는지 기술한다.

$$z_k = H_k x_k + v_k$$

- z_k: 측정 벡터 (센서값)
- H_k: 측정 행렬 (상태 공간에서 측정 공간으로의 변환)
- v_k: 측정 잡음 (센서 노이즈) $\sim \mathcal{N}(0, R_k)$ → 설명했듯이, 가우시안 형태로 가정한다.

마찬가지로 PSI 의 예시로 들어보자면, PSLV 에비오닉스에서는 기압으로 역산한 고도를 측정값으로 활용하고 있다. 즉, 아래와 같이 표현 가능하다.

$$\begin{bmatrix} z_{atm} \\ 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} z \\ v_z \end{bmatrix} + \begin{bmatrix} \epsilon_{z_{atm}} \\ 0 \end{bmatrix}$$

3.3. F와 H의 역할 구분

- F: **시간**에 따른 시스템 **상태**의 변화를 기술 (예: 상태$(k-1)$ → 예측 상태(k)
- H: **동일 시간**(k)에서 **상태**와 **추정값** 간의 관계를 기술 (예: 상태(k) → 추정값(k))

---

4. 칼만 필터 알고리즘 (The Algorithm)

칼만 필터는 예측(Predict)과 갱신(Update) 단계를 반복하며 최적의 상태를 추정한다. 구체적인 Linear 칼만 필터의 작동 구조는 다음과 같다.

아래 내용을 굳이 100% 이해할 필요는 없지만,

1) k-1 추정과 **k 입력**을 가지고 **"k 예측"**을 생성한다. (PSI는 IMU가속도가 입력에 해당)

2) k 예측과 **k 측정**을 가지고 **"k 추정"**을 생성한다. (PSI는 기압고도가 측정에 해당)

의 흐름은 이해할 것을 권장한다.

쉽게 설명하면, 칼만필터는 마치 **닫힌 상자 안의 사람이 속도계만 보고 이동거리를 가늠하는 것과 같다.**

속도계 값 실시간 적분으로 거리를 ***예측*** 하면, 나름 합리적인 계산을 하더라도 오차 누적으로 인해 근본적으로 현재 위치와는 다른 값을 계산하게 된다.

이제 이 사람이, 속도계 관측과 동시에 n초에 한 번씩 GPS로 현재 위치를 확인 한다고 하자.

이것이 ***측정*** 에 해당한다.

예시와 마찬가지로, 실제 칼만 필터를 적용할 때는 입력 값으로 업데이트가 빠른 연속적 값을, 측정값으로는 업데이트가 느리더라도 오차가 작은 값을 선택하는 것이 일반적이다.

4.1 Predict (Time Update)

이전 상태를 바탕으로 현재 상태를 점친다.

1. **상태 예측:** $\hat{x}_k^- = F_k \hat{x}_{k-1} + B_k u_k$
2. **오차 공분산 예측:** $P_k^- = F_k P_{k-1} F_k^T + Q_{k-1}$

4.2 Update (Measurement Update)

예측한 값과 실제 센서값(z_k)을 비교하여 수정한다.

1. **칼만 이득 계산:** $K_k = P_k^- H_k^T (H_k P_k^- H_k^T + R_k)^{-1}$
2. **상태 갱신:** $\hat{x}_k = \hat{x}_k^- + K_k(z_k - H_k \hat{x}_k^-)$
3. **오차 공분산 갱신:** $P_k = (I - K_k H_k) P_k^-$

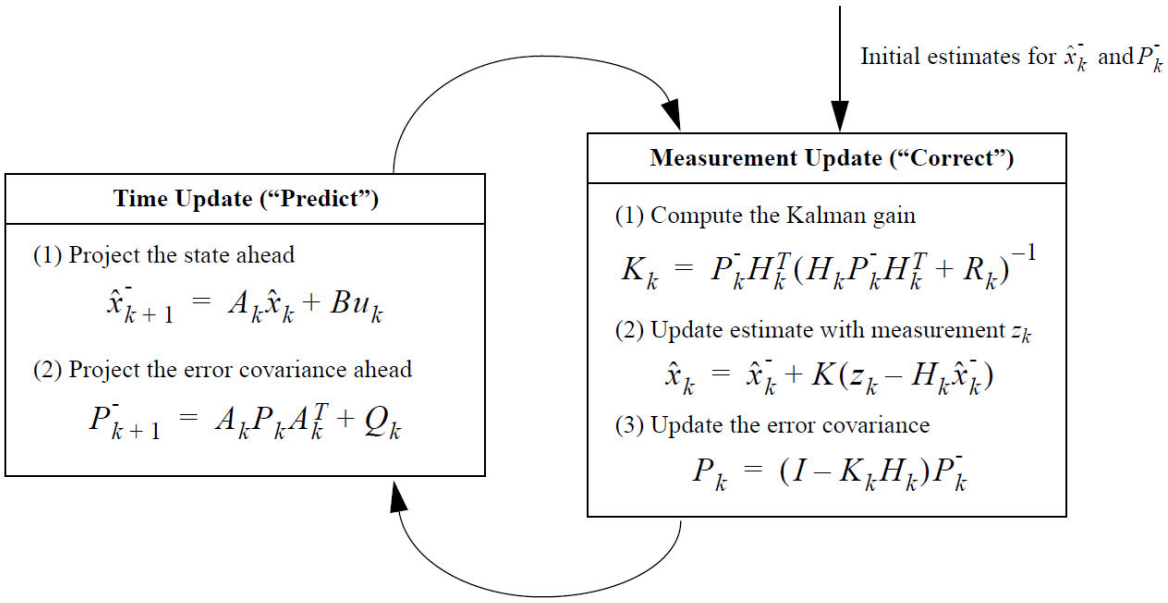

Figure 1-2. A complete picture of the operation of the Kalman filter, combining the high-level diagram of Figure 1-1 with the equations from Table 1-1 and Table 1-2.

5. 수치적 안정성: Joseph Form

컴퓨터 연산 시 부동소수점 오차로 인해 공분산 행렬 P의 대칭성이나 PSD 성질이 깨질 수 있다. 이를 방지하기 위해 보다 안정적인 **Joseph Form** 공분산 갱신 식을 사용한다.

$$P_k = (I - K_k H_k) P_k^- (I - K_k H_k)^T + K_k R_k K_k^T$$

이 형태는 $APA^T + BQB^T$ 구조를 가져 수치적으로 안정적이며, 장시간 비행하는 로켓의 에비오닉스 시스템에서 필터가 발산하는 것을 막아준다.

---

6. 결론: 101-2편으로의 연결

선형 칼만 필터는 선형 시스템과 가우시안 잡음 하에서 **평균 제곱 오차(MSE)를 최소화하는 최적의 추정기**이다. (놀랍게도 이를 수학적으로 증명할 수 있다!) 하지만 우리의 로켓은 비선형적인 공기 저항을 받으며, 기울기가 변함에 따라 좌표계도 복잡하게 뒤틀린다.

즉 추정하고자 한

$$x_k = F_k x_{k-1} + B_k u_k + w_{k-1}$$

모델링이 근본적으로 잘못된 상태 전이임을 의미한다.

다음 편(101-2)에서는 이러한 비선형성의 벽을 넘기 위해, 함수를 선형화하는 대신 확률 분포 자체를 샘플링하여 전달하는 **UKF(Unscented Kalman Filter)**에 대해 다룰 것이다.

Appendix : $P_{k|k} = (I - K_k H_k) P_{k|k-1}$ 의 유도

목표: k 단계에서 추정된 오차 공분산 $P_{k|k} = E[e_{k|k} e_{k|k}^T]$ 의 계산.

$$e_k = x_k - \hat{x}_k$$

(x_k : k 단계에서 실제 상태, $\hat{x}_k$: k 단계에서 추정값)

칼만 필터의 상태 갱신은 다음과 같다고 위에서 소개했다.

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k (z_k - H_k \hat{x}_{k|k-1})$$

이를 사후 오차 정의에 대입하면

$$e_{k|k} = x_k - [\hat{x}_{k|k-1} + K_k (z_k - H_k \hat{x}_{k|k-1})]$$

측정 모델 $z_k = H_k x_k + v_k$ (여기서 v_k는 측정 잡음)를 z_k 자리에 대입하면

$$\begin{aligned}
e_{k|k} &= x_k - [\hat{x}_{k|k-1} + K_k(H_k x_k + v_k - H_k \hat{x}_{k|k-1})] \\
&= x_k - \hat{x}_{k|k-1} - K_k H_k x_k - K_k v_k + K_k H_k \hat{x}_{k|k-1} \\
&= (x_k - \hat{x}_{k|k-1}) - K_k H_k (x_k - \hat{x}_{k|k-1}) - K_k v_k \\
&= e_{k|k-1} - K_k H_k e_{k|k-1} - K_k v_k \\
e_{k|k} &= (I - K_k H_k) e_{k|k-1} - K_k v_k \qquad (*)
\end{aligned}$$

$(*)$을 사용하여 $P_{k|k} = E[e_{k|k} e_{k|k}^T]$를 계산:

$$\begin{aligned}
P_{k|k} &= E[((I - K_k H_k) e_{k|k-1} - K_k v_k)((I - K_k H_k) e_{k|k-1} - K_k v_k)^T] \\
&= E[((I - K_k H_k) e_{k|k-1} - K_k v_k)(e_{k|k-1}^T (I - K_k H_k)^T - v_k^T K_k^T)] \\
&= E[(I - K_k H_k) e_{k|k-1} e_{k|k-1}^T (I - K_k H_k)^T \\
&- (I - K_k H_k) e_{k|k-1} v_k^T K_k^T - K_k v_k e_{k|k-1}^T (I - K_k H_k)^T + K_k v_k v_k^T K_k^T]
\end{aligned}$$

기댓값을 각 항에 적용한다. 이때 사전 오차 $e_{k|k-1}$와 측정 잡음 v_k가 서로 독립(uncorrelated)이므로 중간의 두 cross-terms은 0.

$$\begin{aligned}
P_{k|k} &= E[(I - K_k H_k) e_{k|k-1} e_{k|k-1}^T (I - K_k H_k)^T] + E[K_k v_k v_k^T K_k^T] \\
&= (I - K_k H_k) E[e_{k|k-1} e_{k|k-1}^T] (I - K_k H_k)^T + K_k E[v_k v_k^T] K_k^T
\end{aligned}$$

공분산의 정의에 의해: * $P_{k|k-1} = E[e_{k|k-1} e_{k|k-1}^T]$ (사전 오차 공분산) * $R_k = E[v_k v_k^T]$ (측정 잡음 공분산) 을 대입한 형태를 **Joseph Form** 이라 한다:

$$P_{k|k} = (I - K_k H_k) P_{k|k-1} (I - K_k H_k)^T + K_k R_k K_k^T \qquad (J)$$

Joseph Form (J)에서 더 간단한 공분산 갱신 공식을 유도할 수 있음음 칼만 이득 K_k와 측정 잔차 공분산 S_k의 정의는 다음과 같다:

$$K_k = P_{k|k-1} H_k^T S_k^{-1}$$

$$S_k = H_k P_{k|k-1} H_k^T + R_k$$

Joseph Form을 전개:

$$\begin{aligned}
P_{k|k} &= (I - K_k H_k) P_{k|k-1} (I - H_k^T K_k^T) + K_k R_k K_k^T \\
&= (P_{k|k-1} - K_k H_k P_{k|k-1})(I - H_k^T K_k^T) + K_k R_k K_k^T \\
&= P_{k|k-1} - P_{k|k-1} H_k^T K_k^T - K_k H_k P_{k|k-1} + K_k H_k P_{k|k-1} H_k^T K_k^T + K_k R_k K_k^T \\
&= P_{k|k-1} - K_k H_k P_{k|k-1} - P_{k|k-1} H_k^T K_k^T + K_k (H_k P_{k|k-1} H_k^T + R_k) K_k^T \\
&= P_{k|k-1} - K_k H_k P_{k|k-1} - P_{k|k-1} H_k^T K_k^T + K_k S_k K_k^T
\end{aligned}$$

마지막 항 $K_k S_k K_k^T$에 칼만 이득 정의 $K_k = P_{k|k-1} H_k^T S_k^{-1}$ (즉, $K_k S_k = P_{k|k-1} H_k^T$)를 대입:

$$K_k S_k K_k^T = (P_{k|k-1} H_k^T) K_k^T = P_{k|k-1} H_k^T K_k^T$$

이를 위 식에 다시 대입:

$$
\begin{aligned}
P_{k|k} &= P_{k|k-1} - K_k H_k P_{k|k-1} - P_{k|k-1} H_k^T K_k^T + P_{k|k-1} H_k^T K_k^T \\
&= P_{k|k-1} - K_k H_k P_{k|k-1} \\
&= (I - K_k H_k) P_{k|k-1}
\end{aligned}
$$